Identification des utilisateurs de Copilote

Rapport de bureau d'étude

MOD 7.2 – Introduction à la science des données
Compétition Kaggle – Groupe 2

Version de travail du 12 octobre 2026

État du travail. Cette première version présente le problème, les données et l'exploration initiale déjà effectuée. Aucun modèle n'a été entraîné et aucun score de classification n'est disponible. Les sections consacrées à la suite de l'étude indiquent explicitement les travaux restant à mener. Les auteurs seront renseignés lors de la finalisation du rapport.

1 Introduction

Copilote est un logiciel édité par Infologic pour le secteur agroalimentaire. Son utilisation produit des traces décrivant les actions réalisées au cours d'une session, ainsi que certains éléments de leur contexte. Ces traces permettent d'étudier les habitudes d'utilisation du logiciel : fonctionnalités sollicitées, écrans consultés et interactions effectuées.

Le projet pose la question suivante : peut-on reconnaître un utilisateur à partir d'une session d'utilisation ? Dans le contexte présenté par le BE, les testeurs internes utilisent différents profils pour tester le logiciel. Identifier le testeur à partir de ses traces pourrait faciliter le signalement des problèmes. La reconnaissance des habitudes pourrait aussi contribuer à repérer des comportements inhabituels sur un compte. Cette dernière application constitue une motivation ; elle n'est pas évaluée directement dans les données disponibles.

2 Problématique et objectifs

2.1 Une classification supervisée multiclasse

L'unité d'observation est la **session**. La cible est l'identifiant de l'utilisateur, nommé `util` dans le tableau d'exploration. Le jeu d'entraînement comporte 247 utilisateurs distincts : il s'agit donc d'une classification supervisée à 247 classes. À partir du navigateur et de la séquence de traces d'une session, la solution devra prédire un identifiant utilisateur d'origine.

L'enjeu est de construire une représentation qui distingue les habitudes des utilisateurs malgré la variabilité de leurs sessions. Une fréquence élevée dans l'ensemble du jeu ne suffit pas à prouver qu'une action est discriminante. Il faudra mesurer l'apport des caractéristiques sur des sessions réservées à la validation.

2.2 Cadre du rendu

Les consignes demandent un rapport PDF de 5 à 8 pages, un code Python réexécutable avec ses dépendances et les prédictions sur le jeu de test. Le dépôt des prédictions est prévu sur Moodle et sur la compétition Kaggle du groupe 2. L'échéance annoncée dans le notebook de consignes est le **9 novembre 2026 au soir**. Le rapport final devra justifier les caractéristiques et les méthodes, préciser les métriques et discuter les résultats et leurs limites.

3 Présentation des données et préparation initiale

3.1 Organisation des fichiers

Les données sont fournies sous forme de fichiers texte séparés par des virgules, sans en-tête. Chaque ligne représente une session ; le nombre de champs varie selon la longueur de la séquence. Dans l'entraînement, les deux premiers champs sont l'identifiant utilisateur et le navigateur. Dans le test, l'identifiant est absent et le navigateur est le premier champ.

Fichier	Sessions	Rôle
`train.csv`	3 279	Apprentissage et validation ; identités connues.
`test.csv`	324	Prédictions à produire ; identités non fournies.
`sample_submission.csv`	324	Exemple du format de soumission.

Source : README du projet. L'exploration décrite ici porte uniquement sur le train.

3.2 Contenu d'une trace

Une séquence mêle des actions et des marqueurs temporels. Certaines actions portent des informations supplémentaires, repérées par leurs délimiteurs. Ces informations ne sont pas nécessairement présentes dans chaque action.

Élément	Signification retenue
Nom de l'action	Interaction, par exemple double-clic ou saisie dans un champ.
`(...)`	Écran ou contexte de l'action.
`<...>`	Configuration d'écran.
`$...$`	Chaîne de fiche, regroupement logique dans le logiciel.
Suffixe `1`	Action effectuée en modification dans la fiche.
`tXX`	Repère de fenêtre temporelle exprimé en secondes.

Le nombre total de traces inclut les marqueurs temporels : il ne doit donc pas être confondu avec le nombre d'actions. Le plus grand repère temporel est utilisé comme indicateur descriptif, sans être assimilé à une durée exacte de session. Des repères peuvent être répétés.

3.3 Conservation et contrôles des données

Le notebook lit les lignes une à une et conserve les traces sous forme de listes. Il construit `df_raw` avec quatre colonnes : `session_id`, `util`, `navigateur` et `traces`. Le numéro de ligne sert de repère et ne constitue pas une caractéristique d'identification prévue. Les transformations sont effectuées dans `df_train`. Les listes de traces sont également copiées pour éviter de partager des objets modifiables avec le tableau brut.

Les contrôles enregistrés ne détectent aucune valeur manquante dans les quatre colonnes initiales, aucun identifiant ou navigateur vide et aucun champ de trace vide. Aucun doublon strict n'est observé en comparant l'utilisateur, le navigateur et la séquence complète, sans le numéro de ligne. Cela n'exclut pas des sessions proches ni des anomalies de contenu. Les vérifications finales confirment le même nombre de sessions et la conservation des colonnes brutes dans la copie de travail.

Source : sorties enregistrées de `datamanip/001.ipynb`, jeu d'entraînement.

4 Exploration du jeu d'entraînement

4.1 Répartition des utilisateurs et navigateurs

Les 3 279 sessions se répartissent entre 247 classes. Le nombre de sessions par utilisateur varie de 4 à 75, avec une médiane de 12 et une moyenne de 13,28. Les premier et troisième quartiles sont respectivement 7 et 16. Le déséquilibre des classes et le faible nombre d'exemples de certains utilisateurs devront être pris en compte dans la validation.

Navigateur	Sessions	Part des sessions
Firefox	1 466	44,71 %
Google Chrome	1 339	40,84 %
Microsoft Edge	451	13,75 %
Opera	23	0,70 %

Firefox et Chrome regroupent 85,55 % des sessions. Le croisement entre utilisateur et navigateur montre qu'un seul navigateur est observé pour chacun des 247 utilisateurs dans le train. Plusieurs utilisateurs partagent toutefois le même navigateur : cet indice ne suffit pas à identifier une personne. Sa stabilité dans de nouvelles sessions n'est pas démontrée.

4.2 Longueur des sessions

Les marqueurs reconnus par l'expression régulière `t\d+` sur la totalité de la trace sont séparés des actions. Le notebook calcule ensuite le nombre d'actions, le nombre de marqueurs et le plus grand repère.

Indicateur	Minimum	Q1	Médiane	Q3	Maximum
Actions	0	153	340	818,5	11 977
Marqueurs temporels	1	38	82	197,5	2 491
Dernier repère (s)	5	185	395	945	11 790

La moyenne du nombre d'actions est de 692,36, contre une médiane de 340. Cette différence et le maximum de 11 977 actions indiquent une forte asymétrie des longueurs. Des comptages bruts risquent ainsi de refléter la longueur de la session autant que les habitudes de son utilisateur. La comparaison avec des fréquences normalisées est une piste pour la suite.

4.3 Session sans action

Une session, repérée par `session_id = 1252`, appartient à l'utilisateur `fvc`, sous Google Chrome, et contient uniquement `t5`, `t10` et `t15`. Elle est conservée à ce stade. L'absence d'action n'est pas un champ vide : la session contient des informations temporelles et un navigateur, mais aucun contenu d'action.

La future chaîne de traitement devra accepter ce cas et gérer les ratios dont le dénominateur est nul. L'effet de cette session sur l'apprentissage ou l'évaluation n'a pas encore été mesuré. Sa conservation évite une suppression décidée sans analyse de son incidence.

Source : sorties enregistrées de `datamanip/001.ipynb`, jeu d'entraînement.

4.4 Types d'actions et contextes

Le type d'action est obtenu en séparant le nom des informations de contexte au premier délimiteur parenthèse, chevron ou dollar, puis en retirant l'éventuel suffixe final `1`. Les contextes sont extraits à l'aide des délimiteurs présents dans la trace, sans compléter les valeurs absentes.

Information	Valeurs distinctes	Valeur la plus fréquente
Types d'actions	35	Exécution d'un bouton
Écrans ou contextes	418	`MAINT`
Configurations	219	`DEF_03/24`
Chaînes de fiches	76	`VT`

L'exécution d'un bouton représente 510 645 occurrences et la saisie dans un champ 265 633 occurrences dans l'ensemble du train. Ces comptages portent sur des occurrences, et non sur le nombre de sessions ou d'utilisateurs. Ils sont sensibles aux sessions longues et aux répétitions. Ils ne constituent pas des mesures de l'importance prédictive des actions.

Les écrans, configurations et chaînes peuvent renseigner sur les activités ou les contextes de travail propres à certains utilisateurs. Cette utilité reste une hypothèse. La présence de nombreuses modalités suggère une représentation potentiellement creuse, dont la construction et le traitement des modalités nouvelles devront être définis avant l'entraînement.

4.5 Actions en modification

Le notebook compte comme action en modification toute action terminée par `1`. Pour une session s ayant n_s actions, dont m_s en modification, la proportion est définie par :

$$p_s = \frac{m_s}{n_s} \quad \text{si } n_s > 0.$$

Pour la session sans action, cette proportion est laissée manquante : elle est indéfinie et ne doit pas être interprétée comme une proportion nulle.

Indicateur	Valeur
Médiane du nombre d'actions en modification par session	34
Moyenne du nombre d'actions en modification par session	108,30
Médiane des proportions par session	9,09 %
Moyenne des proportions par session	15,54 %
Sessions avec une proportion définie	3 278
Sessions avec une proportion non définie	1

La moyenne de 15,54 % est la moyenne des proportions sur les sessions dont le ratio est défini. Chaque session y a le même poids ; elle ne correspond pas à la proportion obtenue en regroupant toutes les actions. Le comportement en modification constitue une caractéristique candidate, dont l'apport devra être évalué conjointement avec les autres variables.

4.6 Bilan de l'exploration

Les données sont exploitables sur le plan des contrôles de structure effectués, mais présentent des longueurs très variables et des classes inégalement représentées. Le navigateur, la composition des actions et leurs contextes fournissent des pistes de caractérisation. À ce stade, aucune observation descriptive ne permet de conclure à la fiabilité d'un système d'identification.

Source : sorties enregistrées de `datamanip/001.ipynb`, jeu d'entraînement.

5 Méthodologie envisagée

À réaliser. Construire une représentation par session et comparer son apport en validation. Le tableau ci-dessous décrit des pistes, pas des choix déjà validés ni des modèles déjà entraînés.

Famille	Caractéristiques candidates et question à examiner
Informations globales	Navigateur, nombre d'actions, marqueurs et dernier repère ; apport du contexte et de la longueur.
Actions	Comptages et fréquences par type ; intérêt de normaliser les sessions longues.
Contextes	Présence ou fréquence des écrans, configurations et chaînes ; apport des usages métiers.
Modification	Nombre et proportion d'actions en modification ; traitement explicite du ratio indéfini.
Séquences	Motifs courts ou transitions ; apport éventuel de l'ordre des actions.

Une référence simple, par exemple la prédiction de la classe la plus fréquente de l'apprentissage, permettra de situer les performances. Des classifieurs adaptés à des variables numériques et catégorielles ou à des représentations creuses seront ensuite comparés. La liste finale des méthodes, leurs paramètres et les transformations seront renseignés après les expériences. L'identité cible et le numéro de ligne devront être exclus des variables explicatives.

6 Validation et métriques

À réaliser. Fixer une séparation stratifiée des sessions étiquetées, vérifier la représentation de toutes les classes et consigner la graine aléatoire. Avec au moins quatre sessions par classe, une validation croisée à quatre plis est une option à examiner ; les scores des classes rares resteront sensibles au petit nombre d'exemples.

Les vocabulaires, encodages, normalisations et éventuelles imputations devront être ajustés sur la partie apprentissage de chaque séparation. Les données de validation serviront à comparer les solutions ; le test sans étiquettes ne permet pas de calculer un score local. Une séparation aléatoire par session évalue l'identification sur des sessions réservées, sans démontrer une robustesse à un changement temporel ou d'environnement.

L'accuracy mesurera la proportion de sessions correctement classées. Le F1 combine précision et rappel, avec $F_1 = 2PR/(P + R)$ lorsque le dénominateur est non nul. Le README mentionne un F1 moyen pour Kaggle, mais son mode de moyenne reste à confirmer. Un F1 macro, moyenne non pondérée des F1 par classe, est envisagé en complément pour examiner le déséquilibre ; il ne sera pas présenté comme la métrique officielle tant que ce point n'aura pas été vérifié.

7 Résultats de classification

À réaliser. Présenter les scores de référence et des modèles sur le même protocole, les paramètres retenus et la variabilité éventuelle entre plis. Aucun score, classement Kaggle ou fichier de prédictions n'est disponible à ce stade. Les tableaux descriptifs précédents sont les seuls résultats actuellement documentés.

8 Discussion et conclusion provisoire

À réaliser. Analyser les erreurs, les classes rares et l'apport des familles de variables par des comparaisons avec et sans ces variables. Discuter la dépendance au navigateur et aux contextes, ainsi que la session sans action. Documenter l'environnement effectivement testé : les consignes évoquent Python 3.14, tandis que le dépôt indique actuellement Python 3.11.

L'exploration fournit une base pour construire la chaîne de classification. La prochaine étape est de définir un protocole de validation et une première représentation des sessions, puis de mesurer leurs performances. La solution retenue devra enfin produire 324 prédictions, dans l'ordre du test, aux colonnes `RowId` (de 1 à 324) et `prediction`.

Documents de référence locaux : `README.md` ; `Notebooks/BE_CS1_instructions.ipynb` ; `datamanip/001.ipynb`. Les constats d'exploration proviennent des sorties enregistrées du dernier notebook ; aucune nouvelle expérience de classification n'a été exécutée pour cette rédaction.