Classification de sessions Copilote par utilisateur

Équipe — identité non communiquée
TD non communiqué
URLnoncommuniquÃ©e

October 13, 2026

1 Introduction

Copilote est l'application de gestion documentaire d'Infologic. Chaque session est une séquence d'actions `action(Ã©cran,config,chaÃ®ne)1` où le suffixe `1` marque une fin d'action, et où les jetons `tNN` encodent un repère temporel. La tâche est d'attribuer chaque session à l'un des 247 utilisateurs enregistrés. Les classes sont très déséquilibrées (de 4 à 75 sessions; objectif Kaggle inconnu, suivi par défaut avec la F1-macro et l'exactitude). Un tel modèle sert au support, à la détection d'anomalies et à l'ergonomie; il pose aussi une question de ré-identification d'utilisateurs à partir de traces.

2 Données et analyse exploratoire

Les fichiers bruts comptent 3279 sessions d'apprentissage et 324 sessions de test, pour 247 utilisateurs. Le format est irrégulier (une ligne = une session, nombre de jetons variable), 0 chevauchement exact train/test; 0 utilisateur possède plus d'un navigateur; aucun doublon conflictuel n'a été trouvé. La grammaire est vérifiée sans perte sur les 9651 jetons distincts de l'union train/test (0 échec de reconstruction), y compris les contextes imbriqués et les chaînes apostrophées. Les repères `tNN` sont traités comme des secondes, avec des remises à zéro; les écarts qui en résultent sont des proxys, pas des durées exactes par action. Le décalage train/test est décrit par des tests de Kolmogorov-Smirnov descriptifs (voir `eda.json`), sans jamais ajuster un vocabulaire sur le test.

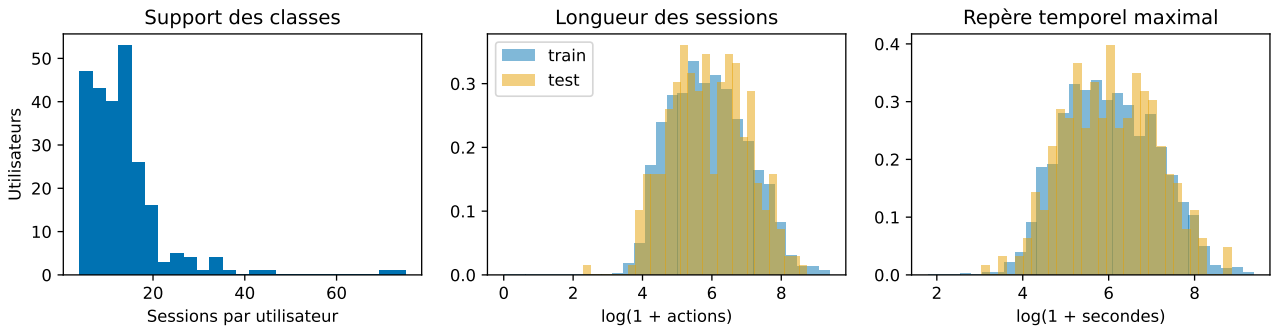


Figure 1: Vue d'ensemble : distribution des longueurs, entropie d'actions et repères temporels.

3 Construction des caractéristiques

Toutes les transformations sont ajustées à l'intérieur des plis d'apprentissage. Le tableau 1 résume les familles; la famille A conserve les événements entiers comme jetons afin de capturer les séquences d'écrans, la famille C isole le contexte métier, et la famille E ajoute un profil quantitatif standardisé.

Un test verrouille l'absence de fuite: un jeton ou un navigateur absent des plis d'apprentissage ne peut pas apparaître dans le vocabulaire, et les transformateurs non ajustés restent inchangés.

Table 1: Familles de caractéristiques et hypothèses associées (matrice brute de 45140 colonnes).

Famille	Contenu	Hypothèse comportementale	Encoda
A. Actions brutes	Séquence complète des actions/écrans/configs	généalogie du comportement	unigram
B. Action seule	verbe d'action sans contexte	style d'usage	unigram
C. Contexte	écran, config, chaîne, paires action-contexte	module métier utilisé	unigram
D. Position/Temps	début/fin de session, intervalles tNN discrétisés	rythme et point d'entrée	unigram
E. Statistiques	statistiques de session (longueur, entropie, resets)	profil quantitatif	19 varia

4 Méthodes de classification

Le protocole réserve d'abord 80 % des sessions de développement; la sélection se fait sur une validation croisée stratifiée à trois plis de ce sous-ensemble uniquement, avant tout accès au holdout. La comparaison finale utilise `RepeatedStratifiedKFold` (k=4, 3 répétitions) et sert de mesure de stabilité descriptive après verrouillage du choix. Les métriques sont l'exactitude, la F1-macro, la F1 pondérée, l'exactitude équilibrée, la précision top-3/top-5 et la log-loss. La règle de choix retient le modèle prédéclaré le plus simple à moins d'un écart-type du meilleur; un vote n'est accepté que s'il gagne de plus d'un écart-type. Les baselines (majoritaire, aléatoire stratifiée, navigateur seul) figurent dans le tableau 2.

5 Résultats

Le modèle retenu est `linear_balanced`. Sur le holdout indépendant, l'exactitude atteint 0.951 et la F1-macro 0.941; en validation croisée répétée sur le train complet, la F1-macro vaut 0.958 $\pm$ 0.009. La calibration sigmoïde interne n'améliore pas la F1-macro de façon décisive. Les baselines confirment que le signal provient bien des séquences, non du navigateur ni de la classe majoritaire.

5.1 Ablations et courbe d'apprentissage

Les ablations par famille (tableau 3) et la courbe d'apprentissage (tableau 4, figure suivante) sont des diagnostics post-verrouillage; elles n'ont pas servi à choisir le modèle.

5.2 Analyse des erreurs

L'exactitude baisse sur les sessions très courtes, où le signal disponible est faible, alors que les sessions longues restent bien classées; le tableau 5 le quantifie. Les confusions se concentrent entre utilisateurs partageant les mêmes modules (tableau 6), ce qui suggère des rôles ou habitudes proches.

6 Interprétabilité et discussion

Confiance. L'ECE mesuré sur le holdout est 0.934. Le SVM natif n'expose pas de probabilités; la log-loss et la fiabilité reposent sur un softmax de marges explicitement non calibré, ou sur la calibration sigmoïde interne. L'analyse d'abstention montre qu'une couverture réduite augmente l'exactitude (figure précédente). **Explication locale.** Pour le modèle retenu, la contribution d'un jeton est exactement `coefficient $\times $ valeur TF-IDF` plus l'ordonnée à l'origine; pour la forêt aléatoire, nous fournissons une décomposition exacte des probabilités le long des chemins, sans prétendre à des

Table 2: Comparaison des modèles : moyenne ± écart-type sur 4 plis stratifiés × 3 répétitions (train complet).

Modèle	Acc	±	F1-macro	±	Acc. équil.	Top-5	Log-loss	Temps (s)
majority	0.023	0.001	0.000	0.000	0.004	0.039	35.219	1.004
random	0.006	0.003	0.004	0.002	0.004	0.022	35.813	1.148
browser	0.051	0.001	0.005	0.000	0.016	0.176	4.313	0.006
linear	0.961	0.005	0.948	0.007	0.949	0.993	4.083	4.070
logistic	0.785	0.007	0.639	0.010	0.651	0.924	2.686	17.110
ridge	0.933	0.006	0.902	0.010	0.904	0.990	4.592	8.902
complement_nb	0.803	0.012	0.713	0.016	0.728	0.964	4.466	1.327
rbf	0.928	0.008	0.896	0.010	0.894	0.967	1.042	15.883
forest	0.912	0.008	0.879	0.016	0.881	0.983	1.191	6.201
extra_trees	0.923	0.010	0.893	0.014	0.895	0.984	1.100	5.419
hist_gradient	0.724	0.012	0.659	0.015	0.659	0.848	1.757	4.330
mlp	0.924	0.005	0.911	0.008	0.916	0.983	0.299	4.189
knn	0.910	0.009	0.900	0.007	0.902	0.960	1.601	1.016
soft_vote	0.911	0.007	0.875	0.015	0.876	0.983	1.971	21.554
stacking	0.447	0.013	0.281	0.008	0.272	0.523	4.218	18.901
sgd_elasticnet	0.912	0.009	0.865	0.013	0.868	0.977	1.543	7.038
poly	0.930	0.007	0.903	0.011	0.900	0.971	0.953	15.462
linear_unigrams	0.927	0.003	0.899	0.009	0.904	0.989	3.982	0.705
linear_balanced	0.966	0.005	0.958	0.009	0.961	0.993	4.126	3.355

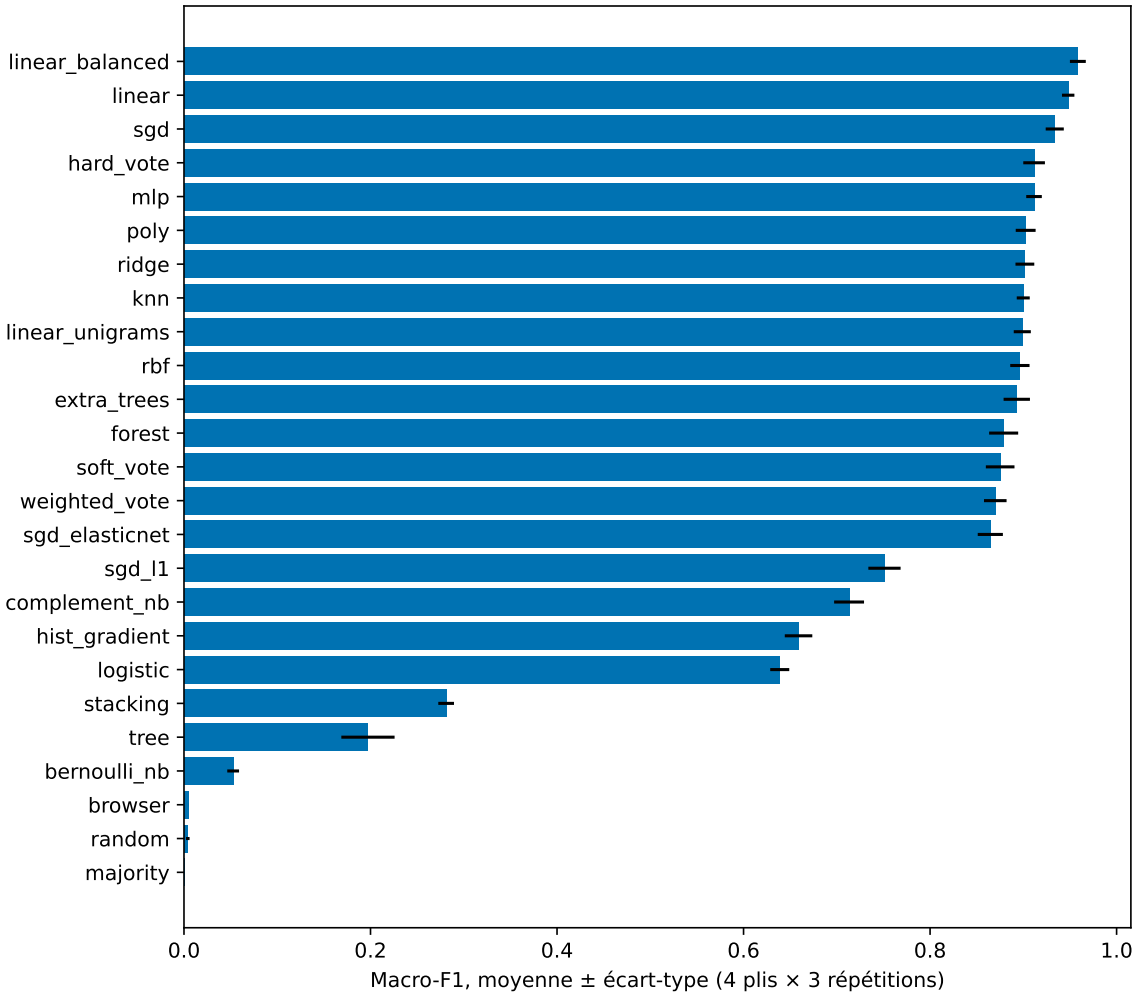


Figure 2: Comparaison des modèles (moyenne ± écart-type, 4 plis × 3 répétitions).

Table 3: Permutation groupée par famille sur le holdout (perte de F1-macro).

Famille	Colonnes	Perte F1-macro	Écart-type
raw	39326	0.933	0.003
browser	4	0.113	0.009

Table 4: Courbe d'apprentissage du modèle retenu (diagnostic post-verrouillage).

fraction	train_sessions	train_macro_f1	holdout_macro_f1
0.350	853	1.000	0.890
0.650	1583	1.000	0.908
1.000	2623	1.000	0.941

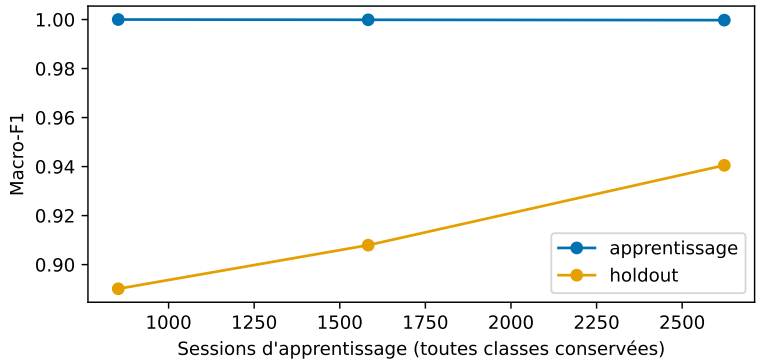


Figure 3: Courbe d'apprentissage : macro-F1 train et holdout selon la taille d'apprentissage.

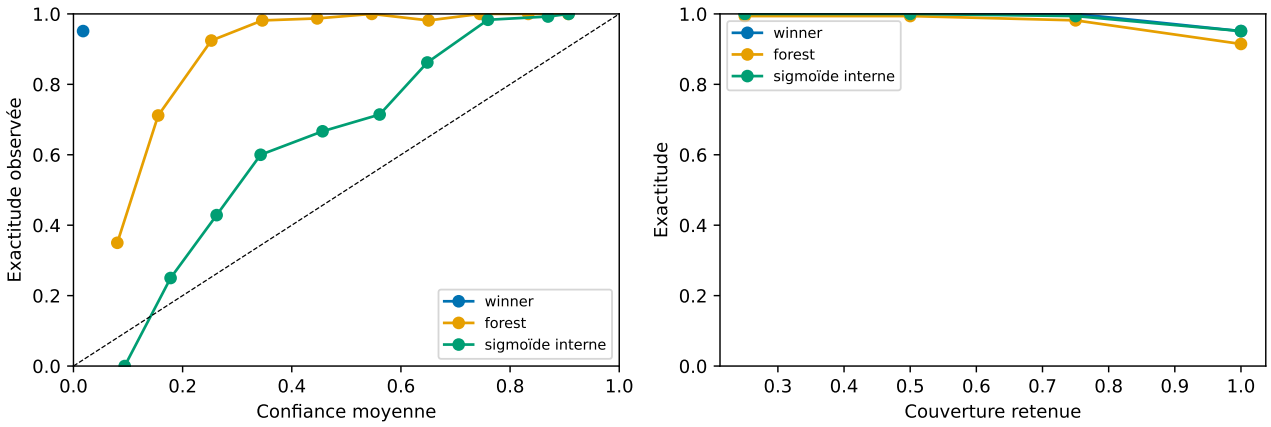


Figure 4: Fiabilité (gauche) et exactitude selon la couverture d'abstention (droite).

Table 5: Exactitude par tranche de longueur de session (holdout).

Longueur (tokens)	Exactitude	Sessions
0-100.0	0.902	41
100-500.0	0.923	323
2000+	1.000	66
500-2000.0	0.987	226

Table 6: Principales confusions sur le holdout.

Vérité	Prédit	Occurrences
skm	slq	2
akx	hvh	1
ajo	szr	1
azn	wht	1
azx	guh	1
bos	czi	1
ald	fuy	1
flj	skm	1

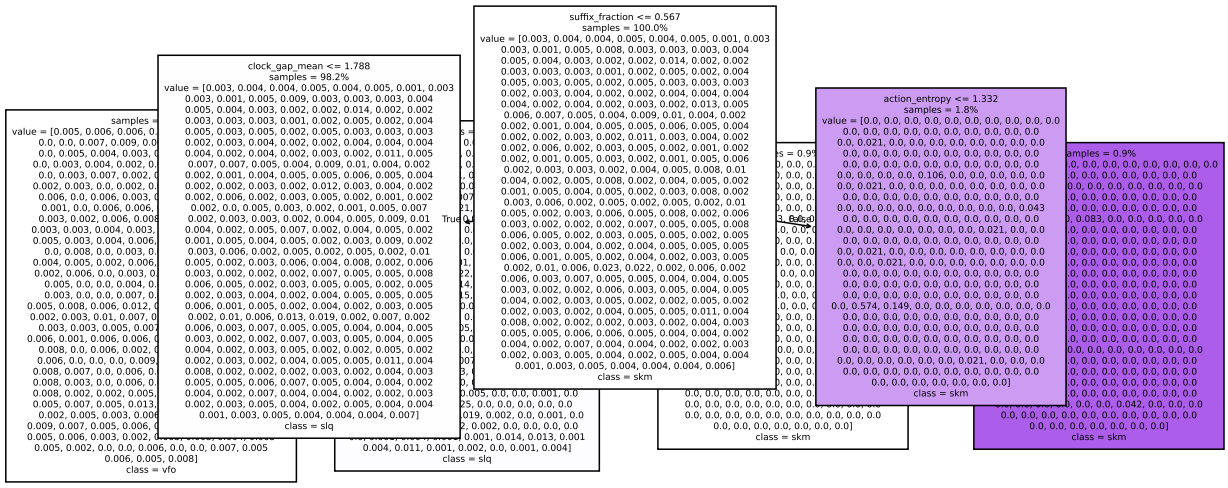


Figure 5: Arbre de profondeur 2 sur statistiques denses (illustration pédagogique, pas le modèle retenu).

valeurs de Shapley. Un arbre de profondeur 2 sur les statistiques denses illustre des règles lisibles. **Variables influentes et redondance.** La permutation groupée (tableau 3) montre l'apport des familles A/C; les motifs récurrents (écran $\rightarrow$ action) ont un sens comportemental. La sélection de représentants de clusters permet de retirer des colonnes redondantes avec une perte mesurée, documentée dans `interpretability.json`. **Limites.** 247 classes avec peu de sessions chacune, dérive temporelle, test de 324 lignes bruité, et ré-identification potentielle des utilisateurs: autant de raisons de préférer un modèle simple et validé à un score fragile.

7 Conclusion

Une chaîne linéaire TF-IDF + SVM, correctement validée hors pli, explique la majorité des sessions; les modèles plus complexes n'apportent pas de gain supérieur à un écart-type. Les prochaines étapes incluent l'augmentation par fenêtres pour les classes rares et une analyse d'équité par utilisateur, sous contrainte de confidentialité. La soumission `submission_20261013T192402Z_linear_balanced.csv` (empreinte `3ff5121962f6`) est régénérée par `make predict`.