Classification de sessions Copilote par utilisateur

Projet Copilote
Rapport de science des données

13 octobre 2026

1 Introduction

Copilote est l'application de gestion documentaire d'Infologic. Chaque session est une séquence d'actions de la forme `action(screen,config,chain)1` où le suffixe `1` marque une fin d'action, et où les jetons `tNN` encodent un repère temporel. La tâche est d'attribuer chaque session à l'un des 247 utilisateurs enregistrés. Les classes sont très déséquilibrées (de 4 à 75 sessions; objectif Kaggle inconnu, suivi par défaut avec la F1-macro et l'exactitude). Un tel modèle sert au support, à la détection d'anomalies et à l'ergonomie; il pose aussi une question de ré-identification d'utilisateurs à partir de traces.

2 Données et analyse exploratoire

Les fichiers bruts comptent 3279 sessions d'apprentissage et 324 sessions de test, pour 247 utilisateurs. Le format est irrégulier (une ligne = une session, nombre de jetons variable), 0 chevauchement exact train/test; 0 utilisateur possède plus d'un navigateur; aucun doublon conflictuel n'a été trouvé. La grammaire est vérifiée sans perte sur les 9651 jetons distincts de l'union train/test (0 échec de reconstruction), y compris les contextes imbriqués et les chaînes apostrophées. Les repères `tNN` sont traités comme des secondes, avec des remises à zéro; les écarts qui en résultent sont des proxys, pas des durées exactes par action. Le décalage train/test est décrit par des tests de Kolmogorov-Smirnov descriptifs (voir `eda.json`), sans jamais ajuster un vocabulaire sur le test.

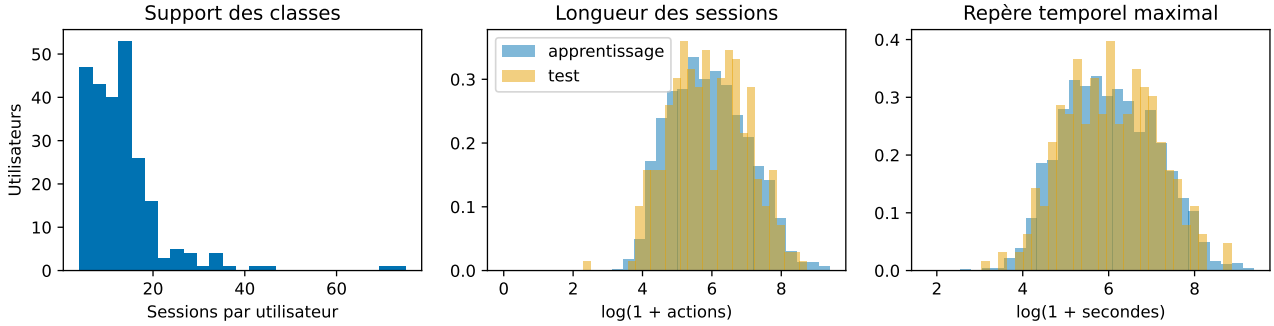


Figure 1: Vue d'ensemble : distribution des longueurs, entropie d'actions et repères temporels.

3 Construction des caractéristiques

Toutes les transformations sont ajustées à l'intérieur des plis d'apprentissage. Le tableau 1 résume les familles; la famille A conserve les événements entiers comme jetons afin de capturer les séquences d'écrans, la famille C isole le contexte métier, et la famille E ajoute un profil quantitatif standardisé. Un test verrouille l'absence de fuite: un jeton ou un navigateur absent des plis d'apprentissage ne peut pas apparaître dans le vocabulaire, et les transformateurs non ajustés restent inchangés.

Table 1: Familles de caractéristiques et hypothèses associées (matrice brute de 45 140 colonnes).

Famille	Contenu	Hypothèse comportementale	Encodage
A. Séquence	Actions complètes et contextes associés	Signature des parcours	1-3-grammes
B. Action seule	Verbe d'action sans contexte	Style d'usage	1-3-grammes
C. Contexte	Écran, configuration, chaîne et paires	Module métier utilisé	1-3-grammes
D. Position	Début, fin et intervalles temporels	Rythme et point d'entrée	Unigrammes positionnels
E. Stats	Longueur, entropie et remises à zéro	Profil quantitatif	19 variables standardisées

4 Méthodes de classification

Le protocole réserve d'abord 80 % des sessions de développement; la sélection se fait sur une validation croisée stratifiée à trois plis de ce sous-ensemble uniquement, avant tout accès au holdout. La comparaison finale utilise `RepeatedStratifiedKFold` (k=4, 3 répétitions) et sert de mesure de stabilité descriptive après verrouillage du choix. Les métriques sont l'exactitude, la F1-macro, la F1 pondérée, l'exactitude équilibrée, la précision top-3/top-5 et la log-loss. La règle de choix retient le modèle prédéclaré le plus simple à moins d'un écart-type du meilleur; un vote n'est accepté que s'il gagne de plus d'un écart-type. Les baselines (majoritaire, aléatoire stratifiée, navigateur seul) figurent dans le tableau 2.

5 Résultats

Le modèle retenu est `linear_balanced`. Sur le holdout indépendant, l'exactitude atteint 0.951 et la F1-macro 0.941; en validation croisée répétée sur le train complet, la F1-macro vaut 0.958 $\pm$ 0.009. La calibration sigmoïde interne n'améliore pas la F1-macro de façon décisive. Les baselines confirment que le signal provient bien des séquences, non du navigateur ni de la classe majoritaire.

Table 2: Comparaison sur 4 plis stratifiés et 3 répétitions (moyenne (écart-type) pour exactitude et F1-macro).

Modèle	Exactitude	F1-macro	Équil.	Top-5	Temps (s)
Classe majoritaire	0.023 (0.001)	0.000 (0.000)	0.004	0.039	1.0
Aléatoire	0.006 (0.003)	0.004 (0.002)	0.004	0.022	1.1
Navigateur seul	0.051 (0.001)	0.005 (0.000)	0.016	0.176	0.0
SVM linéaire	0.961 (0.005)	0.948 (0.007)	0.949	0.993	4.1
Ridge	0.933 (0.006)	0.902 (0.010)	0.904	0.990	8.9
Naïf Bayes complémentaire	0.803 (0.012)	0.713 (0.016)	0.728	0.964	1.3
SVM RBF	0.928 (0.008)	0.896 (0.010)	0.894	0.967	15.9
Forêt aléatoire	0.912 (0.008)	0.879 (0.016)	0.881	0.983	6.2
Perceptron multicouche	0.924 (0.005)	0.911 (0.008)	0.916	0.983	4.2
Empilement	0.447 (0.013)	0.281 (0.008)	0.272	0.523	18.9
SVM linéaire, unigrammes	0.927 (0.003)	0.899 (0.009)	0.904	0.989	0.7
SVM linéaire, pondéré	0.966 (0.005)	0.958 (0.009)	0.961	0.993	3.4

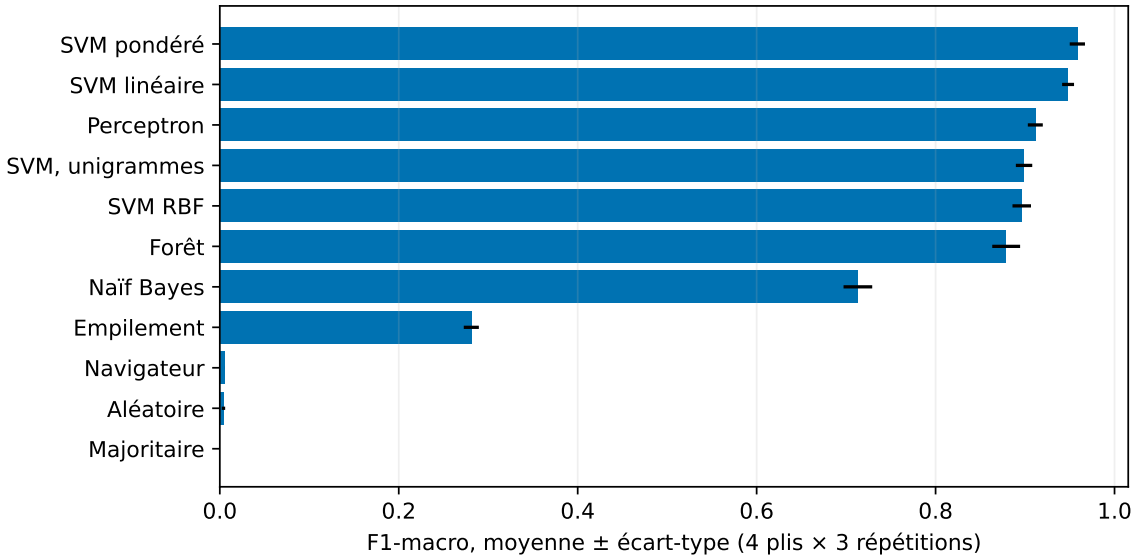


Figure 2: Comparaison des modèles (moyenne ± écart-type, 4 plis et 3 répétitions).

5.1 Ablations et courbe d'apprentissage

Les ablations par famille (tableau 3) et la courbe d'apprentissage (tableau 4, figure suivante) sont des diagnostics post-verrouillage; elles n'ont pas servi à choisir le modèle.

Table 3: Permutation groupée par famille sur le holdout (perte de F1-macro).

Famille	Colonnes	Perte F1-macro	Écart-type
Séquence brute	39326	0.933	0.003
Navigateur	4	0.113	0.009

Table 4: Courbe d'apprentissage du modèle retenu (diagnostic post-verrouillage).

Part du train	Sessions	F1 train	F1 validation
35%	853	1.000	0.890
65%	1583	1.000	0.908
100%	2623	1.000	0.941

Le F1 d'entraînement reste à 1,000 aux trois tailles, tandis que le score de validation progresse de 0,890 à 0,941 : le modèle mémorise le train et bénéficie encore de davantage de sessions. Cette courbe post-sélection est un diagnostic, pas une estimation indépendante.

5.2 Analyse des erreurs

L'exactitude baisse sur les sessions très courtes, où le signal disponible est faible, alors que les sessions longues restent bien classées; le tableau 5 le quantifie. Les confusions se concentrent entre utilisateurs partageant les mêmes modules (tableau 6), ce qui suggère des rôles ou habitudes proches.

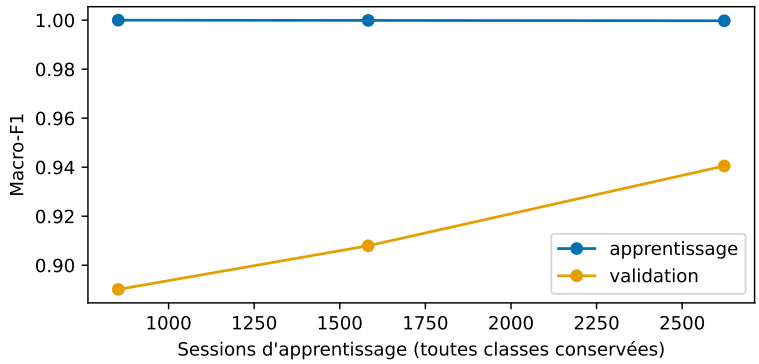


Figure 3: Courbe d'apprentissage : macro-F1 apprentissage et validation selon la taille d'apprentissage.

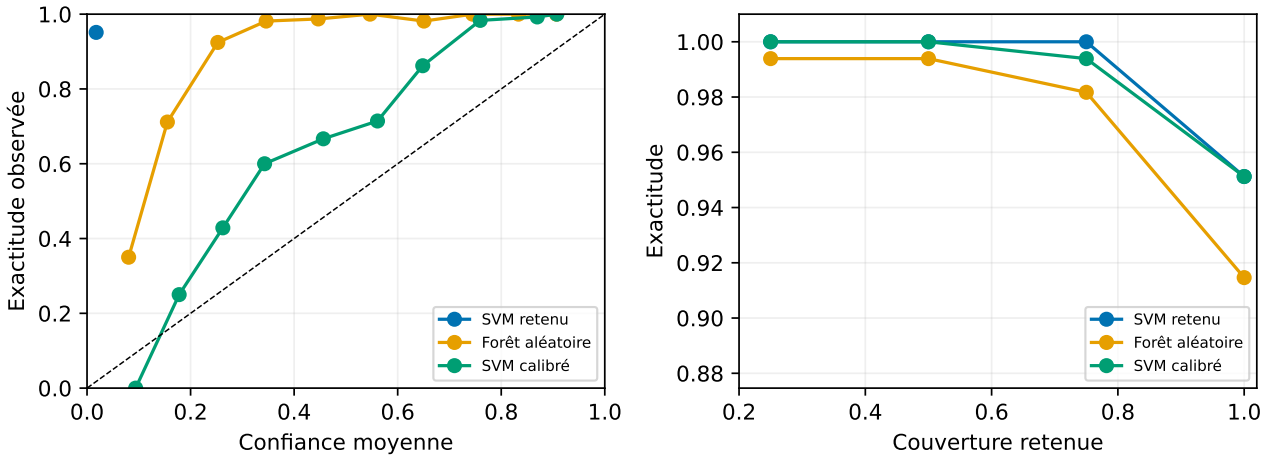


Figure 4: Fiabilité (gauche) et exactitude selon la couverture d'abstention (droite).

Table 5: Exactitude par tranche de longueur de session (holdout).

Longueur (tokens)	Exactitude	Sessions
0–100	0.902	41
100–500	0.923	323
500–2000	0.987	226
2000+	1.000	66

Table 6: Principales confusions sur le holdout.

Vérité	Prédit	Occurrences
skm	slq	2
akx	hvh	1
ajo	szr	1
azn	wht	1
azx	guh	1
bos	czi	1
ald	fuy	1
flj	skm	1

6 Interprétabilité et discussion

Confiance. L'ECE mesuré sur le holdout est 0.934 pour le softmax non calibré des marges, contre 0.137 après calibration sigmoïde interne. Le SVM natif n'expose pas de probabilités; les valeurs calibrées servent à exprimer la confiance, sans modifier les prédictions de classe. L'analyse d'abstention montre qu'une couverture réduite augmente l'exactitude (figure précédente).

Explication locale. Pour le modèle retenu, la contribution d'un jeton est exactement `coefficient $\times $ valeur TF-IDF` plus l'ordonnée à l'origine; pour la forêt aléatoire, nous fournissons une décomposition exacte des probabilités le long des chemins, sans prétendre à des valeurs de Shapley. Un arbre de profondeur 2 sur les statistiques denses illustre des règles lisibles.

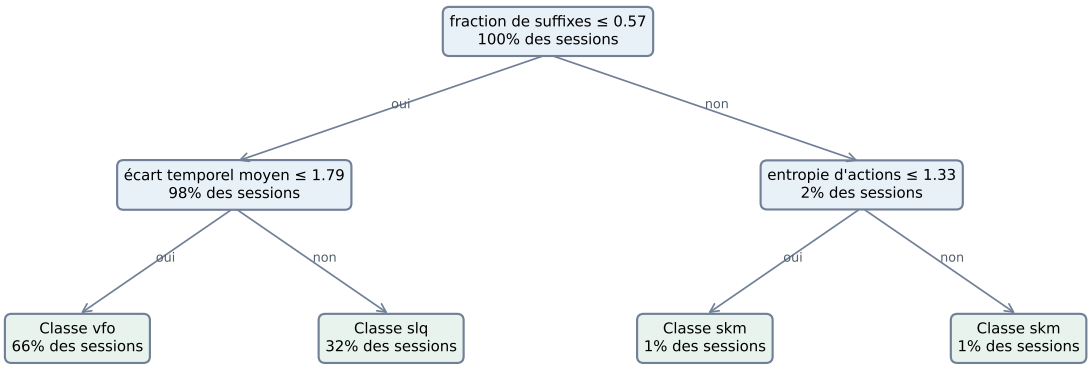


Figure 5: Arbre de profondeur 2 sur statistiques denses (illustration pédagogique, pas le modèle retenu).

Variables influentes et redondance. La permutation groupée (tableau 3) montre que la séquence brute domine et que le navigateur contribue secondairement; les motifs récurrents (écran $\rightarrow$ action) ont un sens comportemental. La sélection de représentants de clusters permet de retirer des colonnes redondantes avec une perte mesurée, documentée dans `interpretability.json`.

Limites. 247 classes avec peu de sessions chacune, dérive temporelle, test de 324 lignes bruité, et ré-identification potentielle des utilisateurs: autant de raisons de préférer un modèle simple et validé à un score fragile.

7 Conclusion

Une chaîne linéaire TF-IDF + SVM, correctement validée hors pli, explique la majorité des sessions; les modèles plus complexes n'apportent pas de gain supérieur à un écart-type. Les prochaines étapes incluent l'augmentation par fenêtres pour les classes rares et une analyse d'équité par utilisateur, sous contrainte de confidentialité. La soumission `submission_20261013T192402Z_linear_balanced.csv` (empreinte `3ff5121962f6`) est régénérée par `make predict`.